Wikia census: cleaning and analysis

Abel Serrano Juste 21 de diciembre, 2018

Índice general

Introducción	1
Problema a resolver	1
Fuentes de datos	2
Descripción del Dataset Wikia census dataset	2 2 7
Limpieza	8
Transformación	10
Análisis	10
Visualización	10
Conclusiones	10
Referencias	10

Introducción

En esta práctica, vamos a realizar un proyecto analítico de ciencia de datos sobre el ecosistema de las wikis. Según la definición de Wikipedia para wiki:

El término wiki (proviene del hawaiano wiki, «rápido») alude al nombre que recibe una comunidad virtual, cuyas páginas son editadas directamente desde el navegador, donde los mismos usuarios crean, modifican, corrigen o eliminan contenidos que, generalmente, comparten.

Las wikis son un interesante objeto de estudio puesto que permiten investigar la colaboración masiva de usuarios online para crear un contenido común.

Utilizaremos los términos usuario y editor indistantemente, puesto que en el contexto de una wiki se pueden entender como sinónimos.

Problema a resolver

Analizar la actividad y diversidad de las wikis alojadas en el servicio Wikia.

Fuentes de datos

Para esta práctica, vamos a usar dos datasets: Wikia census y Wikia page views; ambos disponibles en mi cuenta de kaggle.

- 1. El censo de Wikia. Se trata de un dataset de un conjunto de 300k wikis que corresponde a todas las wikis alojadas en Wikia. Este dataset contiene datos descriptivos de cada wiki como: número de páginas, número de usuarios, número de ediciones, etc. Los métodos de extracción y la información proporcionada en este censo está explicada en el paper: A Wikia census: motives, tools and insights (Jiménez-Díaz, Serrano, y Arroyo 2018).
- 2. Wikia page views. Se trata de una captura de datos, realizada mediante web scrapping de todas las wikis de Wikia, que contiene el número de visitas para cada una de las wikis de Wikia en las últimas cuatro semanas. Este dataset se obtuvo para la práctica anterior de esta misma asignatura y el código fuente para su obtención está en el este repositorio de Github: https://github.com/Akronix/scrap_wikia_page_views.

Descripción del Dataset

Como hemos explicado previamente, vamos a usar dos datasets: el censo de wikia y los números de páginas visitadas.

Wikia census dataset

El primer paso consistirá en cargar los datos:

```
# Cargamos el juego de datos
wikis<-read.csv("data/20181019-wikia_stats_users_birthdate.csv",header=T,sep=",")</pre>
```

A continuación, haremos una breve descripción de los datos, ya que nos interesa tener una idea general de los datos que disponemos. Para ello, primero calcularemos las dimensiones de nuestra base de datos y mostraremos una muestra de los datos para interpretar qué tipos de atributos tenemos.

```
dim(wikis)
```

```
## [1] 277795 32
```

Disponemos de datos de 277795 wikis (filas) con 32 atributos sobre cada uno de ellos (columnas).

head(wikis)

```
##
                                                         url
## 1
                               http://spellmagotm.wikia.com
## 2 http://2017-monster-energy-nascar-cup-series.wikia.com
                        http://10low46japreligion.wikia.com
## 3
                           http://indigo-showdown.wikia.com
## 4
## 5
                                http://animewiki2.wikia.com
## 6
                       http://elena-ofavalor-fans.wikia.com
##
           creation_date
                                                                   domain
## 1 2012-05-01 13:58:13
                                                    spellmagotm.wikia.com
## 2 2017-07-24 22:35:31 2017-monster-energy-nascar-cup-series.wikia.com
## 3 2009-09-15 23:21:34
                                             10low46japreligion.wikia.com
## 4 2014-05-30 15:43:23
                                                indigo-showdown.wikia.com
## 5 2011-02-18 23:15:14
                                                     animewiki2.wikia.com
## 6 2018-09-12 17:52:40
                                            elena-ofavalor-fans.wikia.com
```

```
founding_user_id headline
                                       hub
                                                 id lang language
## 1
              5069110
                                     Games
                                           529058
                                                      en
## 2
             32529801
                                        TV 1601247
                                                      en
## 3
                                              52061
              1602876
                                 Lifestyle
                                                      en
                                                                en
## 4
             25001469
                                     Games
                                            982346
                                                      en
                                                                en
## 5
              1160460
                                        TV
                                            221590
                                                      en
                                                                en
             36888175
                                        TV 1806604
                                                      en
                                                                en
##
                                                         name stats.activeUsers
## 1
                                             Spellmagotm Wiki
## 2
                 2017 Monster Energy NASCAR Cup Series Wiki
                                                                                0
## 3 Ancient Japanese Religion (Daramalan Assignment) Wiki
                                                                                0
                                                                                0
                                        Indigo showdown Wiki
## 4
## 5
                                              Animewiki2 Wiki
                                                                                2
## 6
                                    Elena of avalor fans Wiki
                                                                               -1
     stats.admins stats.articles stats.discussions stats.edits stats.images
## 1
                                 8
                                                               275
## 2
                                45
                                                    0
                                                               230
                                                                              40
                 1
## 3
                 1
                                71
                                                    1
                                                               470
                                                                              20
## 4
                                                               242
                                17
                                                    1
                                                                              11
                 1
## 5
                               102
                                                   NΑ
                                                              6365
                                                                            4938
## 6
                 1
                                                    0
                                                                85
                                                                               0
                                 1
##
     stats.pages stats.users stats.videos
## 1
             229
                     16246020
## 2
             153
                     16555972
                                          4
## 3
             310
                     16117576
             156
                     16387583
                                          2
## 5
            5305
                                           2
                     15397437
## 6
              83
                     15565473
##
                                                        title
                                                                       topic
## 1
                                             Spellmagotm Wiki
                                                                      Gaming
## 2
                 2017 Monster Energy NASCAR Cup Series Wiki Entertainment
## 3 Ancient Japanese Religion (Daramalan Assignment) Wiki
                                                                  Philosophy
## 4
                                        Indigo showdown Wiki
                                                                      Gaming
## 5
                                              Animewiki2 Wiki
                                                                       Anime
## 6
                                    Elena ofavalor fans Wiki Entertainment
     wam_score stats.nonarticles users_1 users_5 users_10 users_20 users_50
##
## 1
        0.0000
                               221
                                         5
                                                  1
## 2
        0.0000
                                         6
                                                  3
                               108
                                                            1
                                                                     1
                                                                               1
## 3
        0.0000
                               239
                                         7
                                                  2
## 4
        0.0000
                                                  4
                                                            3
                                                                     3
                              139
                                         9
                                                                               1
## 5
        0.0161
                              5203
                                        33
                                                           16
                                                 21
                                                                    14
## 6
        0.0000
                                82
                                                                               0
##
     users_100 bots
                                      birthDate datetime.birthDate
                            14:14, May 1, 2012 2012-05-01 14:14:00
## 1
             0
                   5
                          22:35, July 24, 2017 2017-07-24 22:35:00
## 2
             1
                     23:21, September 15, 2009 2009-09-15 23:21:00
## 3
              1
                            15:43, May 30, 2014 2014-05-30 15:43:00
## 4
             0
                   5
                      23:15, February 18, 2011 2011-02-18 23:15:00
## 5
## 6
                   2 17:52, September 12, 2018 2018-09-12 17:52:00
str(wikis)
```

```
## 'data.frame': 277795 obs. of 32 variables:
```

^{## \$} url : Factor w/ 277795 levels "http://0002oifos.wikia.com",..: 225470 532 147 126585 9385 594
\$ creation_date : Factor w/ 276956 levels "2001-01-15 00:00:00",..: 53387 183565 10462 107722 30199 27

```
: Factor w/ 277794 levels "0002oifos.wikia.com",..: 225469 532 147 126584 9385 59413 232
    $ founding_user_id : num 5069110 32529801 1602876 25001469 1160460 ...
   $ headline
                      : Factor w/ 8152 levels "","
                                                                .",..: 1 1 1 1 1 1 1 1 1 1 ...
                         : Factor w/ 8 levels "Books", "Comics", ...: 3 8 4 3 8 8 4 8 8 3 ...
##
    $ hub
##
    $ id
                         : num 529058 1601247 52061 982346 221590 ...
                    : Factor w/ 79 levels "aa", "af", "am", ...: 20 20 20 20 20 20 20 20 20 ...
##
  $ lang
                     : Factor w/ 79 levels "aa", "af", "am", ...: 20 20 20 20 20 20 20 20 20 ...
  $ language
                   : Factor w/ 258804 levels " "," ",..: 175995 608 8765 90942 10708 56819 174447 217529 1
##
##
    $ stats.activeUsers : num 0 0 0 0 2 -1 0 0 0 0 ...
##
    $ stats.admins
                         : num
                               1 1 1 1 1 1 1 1 1 1 ...
##
    $ stats.articles
                         : num
                               8 45 71 17 102 1 6 7 6 4
                               0 0 1 1 NA 0 1 0 0 0 ...
##
    $ stats.discussions : num
##
    $ stats.edits
                        : num 275 230 470 242 6365 ...
    $ stats.images
##
                         : num
                               11 40 20 11 4938 ...
##
                               229 153 310 156 5305 ...
    $ stats.pages
                         : num
##
    $ stats.users
                               16246020 16555972 16117576 16387583 15397437 ...
                         : num
                        : num 0042200000...
##
    $ stats.videos
                                                "," ",..: 175995 608 8765 90942 10708 56819 174447 217529 :
##
  $ title
                   : Factor w/ 258804 levels "
                      : Factor w/ 29 levels "", "Anime", "Auto", ...: 12 8 19 12 2 8 16 9 9 1 ...
   $ topic
##
##
    $ wam score
                               0 0 0 0 0.0161 0 0 0 0
##
   $ stats.nonarticles : num
                               221 108 239 139 5203 ...
                               5 6 7 9 33 3 9 7 4 4 ...
    $ users 1
                         : int
                               1 3 2 4 21 0 1 2 0 1 ...
##
    $ users_5
                         : int
                                1 1 1 3 16 0 0 2 0 1 ...
##
    $ users 10
                         : int
##
    $ users 20
                         : int
                               1 1 1 3 14 0 0 2 0 0 ...
    $ users_50
                         : int
                               1 1 1 1 9 0 0 0 0 0 ...
##
                               0 1 1 0 6 0 0 0 0 0 ...
    $ users_100
                         : int
                         : int 5 4 5 5 3 2 5 6 2 2 ...
##
    $ bots
  $ birthDate
                     : Factor w/ 267762 levels "00:00 10 mar 2013",..: 123272 240694 251221 141386 249826 170
##
   $ datetime.birthDate: Factor w/ 261494 levels "0001-07-28 20:25:00",..: 51943 178041 10093 104783 29390
```

En base a la muestra, al conocimiento sobre el campo en el que estamos trabajando (wikis) y a la descripción proporcionada en el paper "A Wikia census: motives, tools and insights", deducimos los siguientes atributos:

- url: url de la wiki
- creation date: fecha de creación de la wiki en un timestamp
- domain: dominio web de la wiki
- founding_user_id: user id del fundador de la wiki
- headline: ??
- hub: Categoría de la wiki dentro de las definidas por Wikia.
- id: id de la wiki
- lang y language: idioma de la wiki
- name: Nombre propio de la wiki
- stats.activeUsers: número de usuarios activos en el último mes. Los usuarios activos son los usuarios que han hecho al menos una acción (una edición) en los últimos 30 días.
- stats.admins: número de usuarios administradores.
- stats.articles: número de artículos de la wiki.
- stats.discussions: ???
- stats.edits: número de ediciones en la wiki.
- stats.images: número de imágenes subidas.
- stats.pages: número de páginas de la wiki.
- stats.users: número de usuarios registrados en toda Wikia (potencialmente, cualquier podría user usuario de cada wiki porque los usuarios se registran a nivel de toda Wikia).
- stats.videos: número de videos subidos.
- title: título de la wiki

- topic: Temática de la wiki definida por el administrador de la wiki.
- wam_score: Puntuación que le da Wikia a las wikis: http://community.wikia.com/wiki/WAM/FAQ
- stats.nonarticles: número de páginas no artículos en la wiki.
- users_{1,5,10,20,50,100}: Número de usuarios con al menos {una, cinco, diez, veinte, cincuenta, cien} edición(es).
- bots: Número de usuarios de tipo bot (no humanos)
- birthdate: fecha de creación de la wiki en formato natural
- datetime.birthDate: fecha de creación de la wiki en formato datetime de Python

Para terminar con el estudio previo de los datos, pedimos a R que nos muestre un resumen de cómo están distribuidos los valores de los atributos:

summary(wikis)

```
##
                                      url
                                                                creation_date
##
    http://0002oifos.wikia.com
                                               1
                                                   2006-03-16 13:42:45:
##
    http://001-game-creator.wikia.com:
                                                                             79
                                               1
                                                   2004-11-11 23:33:14:
##
    http://001littlebighelp.wikia.com:
                                                                             14
                                               1
                                                   2006-10-28 11:16:22:
##
    http://007fanon.wikia.com
                                               1
                                                   2017-10-16 21:02:01:
                                                                             12
    http://007goldeneye.wikia.com
                                               1
                                                                              8
##
                                                   2017-10-02 21:37:50:
##
    http://007-james-bond.wikia.com
                                               1
                                                   2018-02-08 13:53:15:
                                                                              7
                                        :277789
##
    (Other)
                                                                        :277287
                                                   (Other)
##
                             domain
                                           founding_user_id
##
    cliff-side.wikia.com
                                       2
                                           Min.
                                                            0
##
    0002oifos.wikia.com
                                       1
                                           1st Qu.: 4948217
##
    001-game-creator.wikia.com:
                                       1
                                           Median :25524286
    001littlebighelp.wikia.com:
##
                                       1
                                           Mean
                                                   :20302830
    007fanon.wikia.com
##
                                       1
                                           3rd Qu.:32701075
    007goldeneye.wikia.com
##
                                       1
                                           Max.
                                                   :36902116
    (Other)
                                 :277788
                                           NA's
##
                                                   :35
##
                       headline
                                              hub
                                                                  id
##
                            :269610
                                                 :104758
                                       Games
                                                            Min.
                                                                   :
                                                            1st Qu.: 659216
##
    Assassin's Creed Wiki :
                                  3
                                       Lifestyle: 65294
    The Elder Scrolls Wiki:
                                       TV
##
                                  3
                                                 : 44343
                                                            Median: 1278192
##
    Alice Wiki
                                  2
                                                 : 22619
                                                                    :1137079
                                       Books
                                                            Mean
##
    Animal Crossing Wiki
                                   2
                                       Comics
                                                 : 14545
                                                            3rd Qu.:1685929
##
    Bakugan Wiki
                                  2
                                       Movies
                                                 : 14174
                                                                    :1807291
                                                            Max.
##
    (Other)
                               8173
                                       (Other)
                                                 : 12062
##
         lang
                          language
                                                            name
##
                              :198927
                                         Test Wiki
                                                                   67
    en
            :198927
                       en
##
    es
            : 30372
                       es
                              : 30372
                                         Naruto Wiki
                                                                   59
##
    ru
             12967
                       ru
                              : 12967
                                         Harry Potter Wiki
                                                                   54
##
                                         Pokemon Wiki
                                                                   48
    de
               9176
                       de
                                 9176
                                 7582
##
    pl
               7582
                      pl
                                         Minecraft Wiki
                                                                   44
                                 7029
##
               7029
                                         Final Frontier Wiki:
                                                                   39
    fr
                       fr
##
    (Other): 11742
                       (Other): 11742
                                         (Other)
                                                              :277484
##
    stats.activeUsers
                          stats.admins
                                            stats.articles
##
    Min.
            : -1.000
                         Min.
                                : 0.000
                                            Min.
                                                            0.0
##
                                                            4.0
    1st Qu.:
                0.000
                         1st Qu.:
                                   1.000
                                            1st Qu.:
##
    Median:
                0.000
                         Median:
                                   1.000
                                            Median:
                                                           10.0
                0.823
##
    Mean
                         Mean
                                    1.481
                                            Mean
                                                         122.1
##
    3rd Qu.:
                0.000
                         3rd Qu.:
                                    1.000
                                            3rd Qu.:
                                                           30.0
##
            :7311.000
                         Max.
                                 :248.000
                                            Max.
                                                    :2483023.0
##
    stats.discussions
                          stats.edits
                                               stats.images
```

```
0.00
                                                    -15.0
   Min. :
                      Min. :
                                   0
                                         Min. :
##
   1st Qu.:
               0.00
                      1st Qu.:
                                         1st Qu.:
                                                      1.0
                                   116
               0.00
                                         Median :
   Median :
                      Median :
                                   245
                                                     10.0
               2.97
                                                    210.7
##
   Mean
                      Mean :
                                  2755
                                         Mean :
##
   3rd Qu.:
               1.00
                      3rd Qu.:
                                   470
                                         3rd Qu.:
                                                     40.0
##
   Max.
         :77051.00
                      Max.
                             :23302062
                                         Max.
                                                :784356.0
##
   NA's
          :52295
##
    stats.pages
                      stats.users
                                         stats.videos
                     Min. :
##
   Min.
         :
               -1
                                   -1
                                        Min. :
                                                    0.00
##
   1st Qu.:
               101
                     1st Qu.:16140740
                                        1st Qu.:
                                                    0.00
   Median :
               172
                     Median :16374841
                                        Median :
                                                    7.45
##
   Mean :
              1046
                     Mean :16229539
                                        Mean :
               285
                     3rd Qu.:16555972
##
   3rd Qu.:
                                        3rd Qu.:
                                                    0.00
##
   Max. :7727191
                     Max. :23922667
                                        Max. :51799.00
##
##
                   title
                                          topic
                                                        wam_score
##
                           67
                                Video Games :55625
                                                      Min. : 0.000
   Test Wiki
                      :
                                             :36285
   Naruto Wiki
                           59
                                Gaming
                                                      1st Qu.: 0.000
   Harry Potter Wiki :
                           54
                                Entertainment: 29969
                                                      Median : 0.000
                                                      Mean : 1.064
##
   Pokemon Wiki
                           48
                                Creative
                                             :25359
                                             :23055
##
   Minecraft Wiki
                           44
                                Fanon
                                                      3rd Qu.: 0.000
   Final Frontier Wiki:
                           39
                                TV
                                             :14075
                                                      Max. :99.834
   (Other)
                                             :93427
##
                      :277484
                                (Other)
##
   stats.nonarticles
                        users 1
                                            users 5
##
   Min. :
                                  0.00
                                                     0.0
                -1
                     Min.
                          :
                                         Min. :
                     1st Qu.:
   1st Qu.:
                95
                                  4.00
                                         1st Qu.:
                                                     1.0
##
  Median :
               150
                     Median :
                                  5.00
                                         Median :
                                                     2.0
##
   Mean :
               924
                     Mean
                                 27.48
                                                    11.5
                                         Mean :
##
   3rd Qu.:
               256
                     3rd Qu.:
                                  9.00
                                         3rd Qu.:
                                                     4.0
##
   Max.
         :7725359
                     Max. :127087.00
                                                :32279.0
                                         Max.
##
##
      users_10
                         users_20
                                             users_50
               0.00
                                  0.000
##
   Min. :
                      Min. :
                                          Min. :
                                                      0.000
##
   1st Qu.:
               1.00
                      1st Qu.:
                                  0.000
                                          1st Qu.:
                                                      0.000
                                  1.000
##
   Median :
               1.00
                      Median :
                                          Median :
                                                      1.000
##
   Mean
               7.67
                      Mean
                                  5.044
                                          Mean
                                                      2.813
                                          3rd Qu.:
##
   3rd Qu.:
               3.00
                      3rd Qu.:
                                  2.000
                                                      1.000
##
   Max. :18682.00
                      Max.
                             :15113.000
                                          Max. :11067.000
##
##
                                                           birthDate
     users_100
                           bots
   Min. :
              0.000
                      Min. : 0.000
                                       20:00, December 11, 2013:
                      1st Qu.: 2.000
                                       09:37, September 25, 2006:
##
   1st Qu.:
              0.000
                                                                    348
                                       21:24, February 22, 2018:
   Median:
              0.000
                      Median: 4.000
##
   Mean :
              1.756
                      Mean : 4.135
                                       15:07, October 4, 2016
                                                                    168
   3rd Qu.:
              1.000
                      3rd Qu.: 5.000
                                       21:27 22 feb 2018
                                                                     73
                                       22:19 29 mar 2017
   Max. :8521.000
                      Max. :34.000
                                                                     69
##
##
                                       (Other)
                                                                :276534
##
             datetime.birthDate
   2013-12-11 20:00:00:
                          380
   2006-09-25 09:37:00:
                          348
##
##
   2018-02-22 21:24:00:
                          224
## 2016-10-04 15:07:00:
                          168
## 2018-02-22 21:27:00:
                           73
## 2017-03-29 22:19:00:
                           69
```

```
## (Other) :276533
```

Los campos url y domain son identificadores de la wiki y deberían ser únicos. Aunque tenemos un repetido en el dominio cliff-side.wikia.com que trataremos más adelante.

Ahora podemos deducir que headline se refiere a una especie de subtítulo de la wiki. En cualquier caso, se trata de un campo de texto informativo para los usuarios de la wiki, pero que a nosotros no nos interesa.

Tenemos muchísimas wikis sin videos y también muchas sin imágenes.

Wikia page views dataset

Ahora procedemos a cargar los datos de visitas:

```
# Cargamos el juego de datos
wikis_pgv<-read.csv("data/20181113_wikia-page-views.csv",header=T,sep=",")
head(wikis_pgv)
##
                                                          url visited_pages
                                http://spellmagotm.wikia.com
## 1
## 2 http://2017-monster-energy-nascar-cup-series.wikia.com
                                                                           0
                                                                          0
## 3
                        http://10low46japreligion.wikia.com
## 4
                                                                          0
                                   http://de.bibel.wikia.com
## 5
                            http://indigo-showdown.wikia.com
                                                                          0
## 6
                                 http://animewiki2.wikia.com
                                                                         41
##
     total_views
## 1
               0
## 2
               0
## 3
               0
```

Mostramos información descriptiva de estos datos:

0

2892

0

0

560

4 ## 5

6

Median :

Mean

```
str(wikis_pgv)
## 'data.frame':
                    278889 obs. of 3 variables:
               : Factor w/ 278888 levels "http://0002oifos.wikia.com",..: 225669 511 138 40364 122441 9030 5
    $ visited_pages: int  0 0 0 0 0 41 0 0 5 0 ...
## $ total_views
                   : int 0000056000470...
summary(wikis_pgv)
                                                          visited_pages
##
                                              url
##
    http://pl.6bp-6-batalion-pancerny.wikia.com:
                                                      2
                                                          Min.
                                                                      0.00
##
  http://0002oifos.wikia.com
                                                           1st Qu.:
                                                                      0.00
  http://001-game-creator.wikia.com
                                                          Median :
                                                                      0.00
                                                      1
   http://001littlebighelp.wikia.com
                                                                     12.36
                                                          Mean
   http://007fanon.wikia.com
                                                          3rd Qu.:
                                                                      2.00
##
                                                      1
##
   http://007goldeneye.wikia.com
                                                      1
                                                          Max.
                                                                  :1000.00
##
    (Other)
                                                :278882
##
    total_views
                   0
##
  \mathtt{Min}.
          :
                   0
   1st Qu.:
```

```
## 3rd Qu.: 15
## Max. :20386167
##
```

Observamos que hay una wiki duplicada: http://pl.6bp-6-batalion-pancerny.wikia.com/. También observamos que la mayoría de la wikis (más de la mitad) no han tenido ni una sola visita a sus páginas en las últimas cuatro semanas. Es decir, podríamos considerar que estas wikis están muertas, puesto que ni siquiera usuarios de internet externos a la comunidad las visitan. En el otro extremo tenemos también otras wikis muy populares y así vemos como las medias que obtenemos de tanto páginas visitas como de visitas son mucho mayores que cero. Pero estas wikis que acumulan muchas visitas son escasas y no aparecen hasta más tarde del tercer cuartil de wikis.

Mostramos top 10 wikis con mayor número de visitas:

```
head(wikis_pgv[with(wikis_pgv, order(desc(wikis_pgv$total_views))), ], n = 10)
##
url visited pages total views
```

```
url visited_pages total_views
## 65555 http://oldschoolrunescape.wikia.com
                                                          999
                                                                  20386167
## 156168
                     http://fallout.wikia.com
                                                          996
                                                                  11916618
## 74539
                        http://dnd5e.wikia.com
                                                          676
                                                                  11416101
## 28452
                    http://warframe.wikia.com
                                                          998
                                                                  11165952
## 5484
                http://elderscrolls.wikia.com
                                                          999
                                                                  11160352
## 253171
                      http://naruto.wikia.com
                                                          998
                                                                  9236970
## 246128 http://bokunoheroacademia.wikia.com
                                                          996
                                                                  8660570
## 202431
                     http://reddead.wikia.com
                                                          978
                                                                  7722284
## 228607
                    http://onepiece.wikia.com
                                                          993
                                                                  7543366
## 273208
                      http://yugioh.wikia.com
                                                          996
                                                                  7038509
```

Y top 10 wikis con mayor número de páginas visitadas:

```
head(wikis_pgv[with(wikis_pgv, order(desc(wikis_pgv$visited_pages))), ], n = 10)
```

```
##
                                           url visited_pages total_views
## 24049
                 http://skylanders.wikia.com
                                                        1000
                                                                   384642
## 24429
            http://pokemon-uranium.wikia.com
                                                        1000
                                                                   927726
## 32078
          http://unsolvedmysteries.wikia.com
                                                        1000
                                                                   265778
## 58515
                                                        1000
                      http://fable.wikia.com
                                                                   283271
## 61960
                    http://terraria.wikia.com
                                                        1000
                                                                   607245
## 73099
                 http://yokaiwatch.wikia.com
                                                        1000
                                                                   858819
## 75246
                   http://gamelore.wikia.com
                                                        1000
                                                                    11782
                  http://pl.naruto.wikia.com
## 96655
                                                        1000
                                                                   336321
                  http://saintsrow.wikia.com
## 97769
                                                        1000
                                                                   250143
## 104590
                http://ru.grimdawn.wikia.com
                                                        1000
                                                                   181918
```

Limpieza

Vamos a hacer limpieza de los datos que muestran valores raros o que no deberían estar: Empezamos por tratar que el número de imágenes sea negativo:

Fijaremos a 0 cuando stats.images sea inferior a 0.

```
wikis$stats.images[wikis$stats.images < 0] = 0</pre>
```

Fijaremos a 0 cuando stas.activeUsers sea inferior a 0. (Significa que no tenemos usuarios activos en esa wiki, pero no tiene sentido que tengamos valores menores que 0):

```
wikis$stats.activeUsers[wikis$stats.activeUsers < 0] = 0</pre>
Eliminamos wikis con stats.users o stats.nonarticles o stats.pages menores que cero, puesto que más bien
representan que la wiki no tiene datos válidos (una wiki normal al menos debe tener un usuario registrado
o una página):
invalid_wikis = wikis$stats.users < 0 | wikis$stats.pages < 0 | wikis$stats.nonarticles < 0
dim(wikis[invalid_wikis,]) # number of invalid wikis to delete
## [1] 3 32
wikis = wikis[-invalid_wikis,]
dim(wikis)
## [1] 277794
                  32
Después, vemos qué pasa con los duplicados por dominio:
wikis[duplicated(wikis$domain),]
##
                                             creation_date
                                                                          domain
                                  url
## 128184 http://cliffside.wikia.com 2018-08-18 06:39:50 cliff-side.wikia.com
##
          founding_user_id headline hub
                                               id lang language
## 128184
                    1824669
                                      TV 1788785
                                                    en
                                                              en CliffSide Wiki
##
          stats.activeUsers stats.admins stats.articles stats.discussions
## 128184
                           1
                                        1
##
          stats.edits stats.images stats.pages stats.users stats.videos
## 128184
                  859
                                173
                                             393
                                                    15621017
##
                                  topic wam_score stats.nonarticles users_1
                    title
## 128184 CliffSide Wiki Entertainment
                                                 0
          users_5 users_10 users_20 users_50 users_100 bots
## 128184
                1
                          1
                                   1
                                            1
##
                        birthDate datetime.birthDate
## 128184 06:40, August 18, 2018 2018-08-18 06:40:00
#wikis[domain == "cliff-side.wikia.com", ] # Solo hay este dominio duplicado
# el dominio cliff-side.wikia.com está repetido. Eliminamos el último:
wikis = wikis[-duplicated(wikis$domain),]
dim(wikis)
## [1] 277793
                  32
Eliminamos también el duplicado que hemos visto para los datos de las visitas:
wikis_pgv = wikis_pgv[!duplicated(wikis_pgv$url),]
summary(wikis_pgv)
##
                                    url
                                                 visited_pages
    http://0002oifos.wikia.com
##
                                      :
                                             1
                                                 Min.
                                                             0.00
##
   http://001-game-creator.wikia.com:
                                                             0.00
                                             1
                                                 1st Qu.:
## http://001littlebighelp.wikia.com:
                                                 Median:
                                                             0.00
## http://007fanon.wikia.com
                                             1
                                                 Mean
                                                           12.36
## http://007goldeneye.wikia.com
                                             1
                                                 3rd Qu.:
                                                            2.00
## http://007-james-bond.wikia.com :
                                             1
                                                 Max.
                                                        :1000.00
##
   (Other)
                                      :278882
##
    total_views
##
   Min.
                    0
          :
##
   1st Qu.:
                    0
```

Median :

Mean : 2892 ## 3rd Qu.: 15 ## Max. :20386167

##

Transformación

Análisis

Visualización

Conclusiones

Referencias

Jiménez-Díaz, Guillermo, Abel Serrano, y Javier Arroyo. 2018. «A Wikia census: motives, tools and insights». En $Proceedings\ of\ Opensym\ 2018,\ 12:1-12:7.\ ACM.$